

Практичне заняття 7

STAT250: Теорія ймовірностей та статистика

Ihor Miroshnychenko
Kyiv School of Economics

2026-06-22

Table of contents

1. Перевірка узгодженості розподілів та таблиці спряженості	1
1.1. Питання для розгляду	1
1.2. Задача 1. Перевірка нормальності: тест Шапіро–Вілکا (<i>iris</i>)	4
1.3. Задача 2. Тест Колмогорова–Смирнова (<i>palmerpenguins</i>)	6
1.4. Задача 3. Хі-квадрат узгодженості: чи чесна гральна кістка?	8
1.5. Задача 4. Хі-квадрат узгодженості: огранки діамантів (<i>diamonds</i>)	10
1.6. Задача 5. Хі-квадрат незалежності: стаття і вид спорту	12
1.7. Задача 6. Хі-квадрат незалежності: куріння і стаття (<i>MASS::survey</i>)	13
2. Підсумок	15

1. Перевірка узгодженості розподілів та таблиці спряженості

1.1. Питання для розгляду

1.1.1. 1. Чим тести узгодженості відрізняються від t -тестів?

Відповідь. На минулому занятті t -тести відповідали на питання про **число** — середнє: «Чи дорівнює μ якомусь значенню?», «Чи рівні два середніх?». Сьогодні питання інакші — про **форму** та **структуру** даних:

Питання	Тест
Чи мають дані нормальну форму?	Шапіро–Вілка, Колмогорова–Смирнова
Чи трапляються категорії так часто, як ми очікуємо?	χ^2 узгодженості
Чи пов'язані дві категоріальні ознаки?	χ^2 незалежності

Спільне в усіх тестів одне: ми формулюємо H_0 , рахуємо **статистику**, яка під H_0 має відомий розподіл, і дивимось на p -value. Якщо $p < \alpha$ — відхиляємо H_0 .

1.1.2. 2. Що таке емпірична функція розподілу (ECDF)?

Відповідь. Це «сходінкова» функція, яка для кожного значення x показує **частку спостережень**, що не перевищують x :

$$\hat{F}_n(x) = \frac{1}{n} \sum_{k=1}^n \mathbf{1}\{X_k \leq x\}.$$

Простими словами: станьте у точці x на осі й порахуйте, яка частка ваших даних опинилася ліворуч. За **теоремою Глівенка–Кантеллі** при зростанні n ця емпірична крива дедалі точніше повторює справжню функцію розподілу. Саме на порівнянні $\hat{F}_n$ з теоретичною кривою побудований тест Колмогорова–Смирнова.

1.1.3. 3. Як працює тест Колмогорова–Смирнова?

Відповідь. Він перевіряє, чи збігається розподіл даних із заданим неперервним розподілом F_0 (наприклад, нормальним). Статистика — **найбільший вертикальний розрив** між емпіричною та теоретичною кривими:

$$D_n = \sup_x |\hat{F}_n(x) - F_0(x)|.$$

Інтуїція: малюємо обидві криві на одному графіку й шукаємо точку, де вони найбільше розходяться. Велике $D_n \rightarrow$ дані погано лягають на $F_0 \rightarrow$ малий p -value $\rightarrow$ відхиляємо H_0 . Перевага KS у тому, що він універсальний: F_0 може бути будь-яким (нормальний, експоненційний, рівномірний...).

1.1.4. 4. Чим тест Шапіро–Вілка відрізняється від KS?

Відповідь. Шапіро–Вілка «заточений» **лише під нормальність**. Він порівнює впорядковані значення вибірки з тим, якими вони мали б бути для нормального розподілу. Статистика $W \in (0, 1]$:

- W близьке до 1 $\rightarrow$ дані схожі на нормальні;
- W помітно менше 1 $\rightarrow$ є відхилення.

Для перевірки **саме нормальності** Шапіро–Вілка зазвичай **потужніший** за KS (краще виявляє відхилення). Тому на практиці правило таке: хочете перевірити нормальність — беріть Шапіро–Вілка; хочете перевірити узгодженість із якимось іншим розподілом — беріть KS.

1.1.5. 5. Що таке Q–Q графік і як його читати?

Відповідь. Q–Q графік (quantile–quantile) ставить у відповідність квантилі ваших даних і квантилі еталонного (нормального) розподілу. Якщо точки лягають **уздовж прямої лінії** — дані близькі до нормальних. Систематичні викривлення підказують характер відхилення:

- «хвіст» угору/вниз на кінцях $\rightarrow$ важкі хвости або викиди;
- S-подібний вигин $\rightarrow$ скошеність.

Це **неформальний візуальний** інструмент, який добре доповнює формальний тест: p -value каже «так/ні», а Q–Q графік показує **чому**.

1.1.6. 6. Що таке розподіл хі-квадрат і звідки він береться?

Відповідь. Якщо взяти n незалежних стандартних нормальних величин $Z_1, \dots, Z_n$ і скласти їхні квадрати, отримаємо величину з розподілом χ_n^2 :

$$\chi_n^2 = \sum_{i=1}^n Z_i^2.$$

Через піднесення до квадрата ця величина **завжди невід’ємна** і її розподіл **праворуч скошений**. Саме тому статистика будь-якого χ^2 -тесту (де ми додаємо квадрати відхилень) **теж невід’ємна**, і відхиляємо H_0 ми лише за **великих** її значень.

1.1.7. 7. Як влаштований тест хі-квадрат узгодженості?

Відповідь. Дані розбиті на k категорій. Для кожної є **спостережена** частота O_i і **очікувана** $E_i = np_i$ (скільки б ми бачили, якби H_0 була правдою). Статистика складає відносні квадрати розбіжностей:

$$\hat{\chi}^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}.$$

Кожен доданок питає: «наскільки сильно ця категорія відхилилась від очікування?». Якщо всі $O_i \approx E_i$, сума мала $\rightarrow H_0$ узгоджується з даними. Велика сума $\rightarrow$ категорії поводяться не так, як передбачає H_0 .

1.1.8. 8. Що таке ступені свободи у хі-квадрат тестах?

Відповідь. Це кількість «незалежних» доданків у статистиці.

- **Узгодженість:** $df = k - 1 - m$, де k — число категорій, m — число параметрів, оцінених із даних. « -1 » — бо частоти мають у сумі давати n (остання визначається рештою). Для чесної кістки параметрів не оцінюємо: $df = k - 1$.
- **Незалежність:** $df = (k - 1)(m - 1)$ для таблиці $k \times m$.

Ступені свободи задають конкретну криву χ^2 , з якою порівнюємо статистику.

1.1.9. 9. Як працює тест хі-квадрат на незалежність?

Відповідь. Маємо **таблицю спряженості** — підрахунок, скільки спостережень потрапило в кожну комбінацію категорій двох ознак. H_0 : ознаки **незалежні**. Тоді очікувану частоту в клітинці рахуємо з добутку маргінальних сум:

$$E_{il} = \frac{(\text{сума рядка } i) \times (\text{сума стовпця } l)}{n}.$$

Далі — та сама формула $\sum (O - E)^2 / E$. Логіка проста: за незалежності частка, скажімо, тенісистів має бути однаковою серед чоловіків і жінок. Якщо реальні частоти сильно відхиляються від цього «незалежного» очікування — ознаки пов’язані.

1.1.10. 10. Які умови застосовності хі-квадрат тестів?

Відповідь.

1. **Незалежність** спостережень.
2. **Очікувані** частоти $E_i \geq 5$ у (майже) кожній категорії — інакше наближення хі-квадратом ненадійне (тоді беруть точний тест Фішера або об’єднують категорії).
3. Для таблиць 2×2 застосовують **поправку Єйтса** на неперервність (R робить її за замовчуванням), бо при одному ступені свободи дискретність помітно впливає.

1.1.11. 11. Чому при великій вибірці майже все стає «значущим»?

Відповідь. p -value відповідає на питання «чи є відхилення?», а **не** «чи воно велике?». Що більший n , то менші відхилення тест здатний «побачити». На датасеті з десятків тисяч спостережень (як

diamonds) навіть крихітна нерівномірність дасть $p < 0.001$. Тому завжди дивіться не лише на p -value, а й на **розмір** ефекту: порівнюйте O_i з E_i , стандартизовані залишки, частки.

1.2. Задача 1. Перевірка нормальності: тест Шапіро–Вілка (**iris**)

Вбудований датасет **iris** містить виміри 150 квіток трьох видів ірисів. Розгляньте **довжину чашолистка** (**Sepal.Length**) лише для виду **Setosa** ($n = 50$). Чи можна вважати її нормально розподіленою? Побудуйте гістограму та Q–Q графік, виконайте тест Шапіро–Вілка на рівні значущості $\alpha = 0.05$.

$$H_0 : X \sim \mathcal{N}(\mu, \sigma^2) \quad \text{проти} \quad H_a : X \not\sim \mathcal{N}(\mu, \sigma^2).$$

1.2.1. Що ми робимо і навіщо

Багато класичних методів (t -тести, лінійна регресія) спираються на припущення про нормальність. Перш ніж їх застосовувати, варто це припущення **перевірити**. Зробимо це двома способами: спершу подивимось на дані очима (гістограма + Q–Q графік), а потім — формальним тестом Шапіро–Вілка.

1.2.2. Розв’язання в R



Спочатку візуальна діагностика:

```
setosa <- iris$Sepal.Length[iris$Species == "setosa"]

p_hist <- tibble(x = setosa) |>
  ggplot(aes(x)) +
  geom_histogram(aes(y = after_stat(density)), bins = 10,
                 fill = "#4393c3", color = "white", alpha = 0.8) +
  stat_function(fun = dnorm, args = list(mean = mean(setosa), sd = sd(setosa)),
               color = "#d73027", linewidth = 1) +
  labs(title = "Гістограма + нормальна крива", x = "Sepal.Length", y = "Щільність") +
  theme_minimal(base_size = 12)

p_qq <- tibble(x = setosa) |>
  ggplot(aes(sample = x)) +
  stat_qq(color = "#2166ac") +
  stat_qq_line(color = "#d73027", linewidth = 1) +
  labs(title = "Q–Q графік", x = "Теоретичні квантилі", y = "Вибіркові квантилі") +
  theme_minimal(base_size = 12)

p_hist + p_qq
```



Гістограма приблизно симетрична й непогано лягає на червону нормальну криву, а точки на Q–Q графіку тримаються діагоналі. Тепер формальна перевірка:

```
shapiro.test(setosa)
```

Shapiro-Wilk normality test

```
data: setosa
W = 0.9777, p-value = 0.4595
```

1.2.3. Детальний розбір результату

Статистика $W \approx 0.978$ — дуже близька до 1, тобто впорядкована вибірка майже така, якою її «очікує» нормальний розподіл. Головне число — **$p\text{-value} \approx 0.46$** .

Як його читати: якби дані справді були нормальними, побачити таку вибірку (або «менш нормальну») цілком звично — це трапляється у ~46% випадків. Це **набагато більше** за поріг $\alpha = 0.05$.

Інтерпретація. $p \approx 0.46 > 0.05 \rightarrow$ **не відхиляємо H_0** . Доказів проти нормальності немає: гістограма симетрична, точки Q–Q графіка на діагоналі. Для довжини чашолистка Setosa припущення про нормальність **виправдане**, тож t -тести тут застосовувати коректно.

Важливо: «не відхилили H_0 » означає лише, що **підстав сумніватися немає** — це не доказ ідеальної нормальності. Це як виправдувальний вирок: «недостатньо доказів провини», а не «доведена невинність».

1.3. Задача 2. Тест Колмогорова–Смирнова (`palmerpenguins`)

Датасет `palmerpenguins::penguins` містить виміри пінгвінів Антарктики. Візьміть **масу тіла** (`body_mass_g`) виду **Adelie**, прибери́ть пропуски ($n = 151$) і **стандартизуйте** її. За допомогою тесту Колмогорова–Смирнова перевірте, чи відповідає вона стандартному нормальному розподілу. Порівняйте висновок із тестом Шапіро–Вілка.

$$H_0 : F(x) = \Phi(x) \quad \text{проти} \quad H_a : F(x) \neq \Phi(x).$$

1.3.1. Що означає «стандартизувати» і навіщо

KS-тест порівнює дані з **конкретним** розподілом. Щоб звіряти з *стандартним* нормальним $\mathcal{N}(0, 1)$, дані спершу переводять у z -оцінки:

$$z_i = \frac{x_i - \bar{x}}{s}.$$

Після цього вибірка має середнє 0 і стандартне відхилення 1, тож її коректно порівнювати з $\Phi(x)$ — функцією розподілу $\mathcal{N}(0, 1)$.

1.3.2. Розв’язання в R

```
adelie <- penguins |>
  filter(species == "Adelie", !is.na(body_mass_g))

z <- as.numeric(scale(adelie$body_mass_g)) # стандартизація: (x - x̄) / s

ks.test(z, "pnorm", mean = 0, sd = 1)
```

Asymptotic one-sample Kolmogorov-Smirnov test

```
data: z
D = 0.072461, p-value = 0.4061
alternative hypothesis: two-sided
```

Подивимось на емпіричну та теоретичну криві — саме відстань між ними й вимірює статистика D_n :

```
grid <- seq(min(z), max(z), length.out = 200)


tibble(x = grid, theoretical = pnorm(grid)) |>
  ggplot() +
  stat_ecdf(data = tibble(z = z), aes(z, color = "Емпірична (f̂n)",
    geom = "step", linewidth = 1) +
  geom_line(aes(x, theoretical, color = "Теоретична (Φ)"), linewidth = 1) +
  scale_color_manual(values = c("Емпірична (f̂n)" = "#2166ac", "Теоретична (Φ)" =
```

```

"#d73027")) +
  labs(title = "ECDF маси тіла Adelie проти стандартної нормальної CDF",
        x = "Стандартизована маса тіла", y = "F(x)", color = NULL) +
  theme_minimal(base_size = 12) +
  theme(legend.position = "top")

```

ECDF маси тіла Adelie проти стандартної нормальної CDF



Криві майже накладаються — найбільший розрив $D_n \approx 0.07$ невеликий, тому $p \approx 0.41$. Тепер той самий набір перевіримо тестом Шапіро–Вілка:

```
shapiro.test(adelie$body_mass_g)$p.value
```

```
[1] 0.03239702
```

1.3.3. Детальний розбір: чому два тести «сперечаються»

Маємо цікаву ситуацію — тести дають **різні висновки**:

Тест	Статистика	p -value	Рішення при $\alpha = 0.05$
Кол- мого- рова- Смир- нова	$D \approx 0.07$	≈ 0.41	не відхиляємо H_0
Шапі- ро-Віл- ка	$W \approx 0.98$	≈ 0.032	відхиляємо H_0

Інтерпретація. KS не бачить проблеми, а Шапіро–Вілка фіксує незначне відхилення від нормальності. Це не помилка, а ілюстрація **різної потужності**: Шапіро–Вілка чутливіший і при $n = 151$ вловлює невелику скошеність, якої «грубіший» KS не помічає.

Практичні висновки:

- Для перевірки **нормальності** надавайте перевагу **Шапіро–Вілка** — він майже завжди потужніший.
- **KS** залишайте для випадків, коли треба звірити дані з *будь-яким іншим* заданим розподілом (експоненційним, рівномірним тощо).
- Завжди дивіться на **Q–Q графік**: формальні p -value корисні, але саме графік показує, що відхилення тут невелике й практично, ймовірно, неістотне.

Технічна примітка. Якщо у даних є однакові значення (ties), p -value KS наближений — R про це попереджає. А коли μ і σ оцінено з тієї ж вибірки (як у нас), формально коректнішим є тест Ліллієфорса (`nortest::lillie.test`).

1.4. Задача 3. Хі-квадрат узгодженості: чи чесна гральна кістка?

Шестигранну кістку кинули **60 разів** і отримали такі частоти граней:

Грань	1	2	3	4	5	6
O_i	13	8	12	10	7	10

На рівні значущості $\alpha = 0.05$ перевірте, чи кістка чесна (грані випадають рівноймовірно).

$$H_0 : p_i = \frac{1}{6} \forall i \quad \text{проти} \quad H_a : \text{хоча б одне } p_i \neq \frac{1}{6}.$$

1.4.1. Математичне розв’язання

Крок 1. Очікувані частоти. Якщо кістка чесна, кожна грань має ймовірність $1/6$, тож за 60 кидків очікуємо однакову кількість для всіх граней:

$$E_i = np_i = 60 \cdot \frac{1}{6} = 10.$$

Крок 2. Статистика. Для кожної грані рахуємо $(O_i - E_i)^2 / E_i$ і додаємо:

$$\begin{aligned} \chi^2 &= \frac{(13 - 10)^2 + (8 - 10)^2 + (12 - 10)^2 + (10 - 10)^2 + (7 - 10)^2 + (10 - 10)^2}{10} \\ &= \frac{9 + 4 + 4 + 0 + 9 + 0}{10} = \frac{26}{10} = 2.6. \end{aligned}$$

Крок 3. Ступені свободи й критичне значення. Параметрів не оцінювали, тож $df = k - 1 = 6 - 1 = 5$. З таблиці: $\chi_{0.95, 5}^2 \approx 11.07$.

Крок 4. Рішення. $\hat{\chi}^2 = 2.6 < 11.07 \rightarrow$ не виходимо за межу $\rightarrow$ **не відхиляємо H_0 .**

1.4.2. Розв'язання в R

```
observed <- c(13, 8, 12, 10, 7, 10)
chisq.test(observed, p = rep(1/6, 6))
```

Chi-squared test for given probabilities

```
data: observed
X-squared = 2.6, df = 5, p-value = 0.7614
```

Функція `chisq.test` із аргументом `p` (очікувані ймовірності) робить рівно те, що ми порахували вручну: бачимо ту саму статистику $X^2 = 2.6$, $df = 5$.


1.4.3. Детальний розбір результату

p -value ≈ 0.76 — величезне. Це означає: якби кістка справді була чесною, отримати таке (або більше) відхилення абсолютно нормально — у $\sim 76\%$ випадків. Відхилення $\{+3, -2, +2, 0, -3, 0\}$ — звичайний випадковий шум.

Інтерпретація. $\hat{\chi}^2 = 2.6$, $p \approx 0.76 \gg 0.05 \rightarrow$ **не відхиляємо H_0 .** Даних недостатньо, щоб засумніватися в чесності кістки; спостережені розбіжності пояснюються випадковістю.

```
tibble(face = factor(1:6), Спостережено = observed, Очікувано = 10) |>
  pivot_longer(-face, names_to = "type", values_to = "freq") |>
  ggplot(aes(face, freq, fill = type)) +
  geom_col(position = "dodge", alpha = 0.85) +
  scale_fill_manual(values = c("Спостережено" = "#4393c3", "Очікувано" = "grey60")) +
  labs(title = "Кістка: спостережені vs очікувані частоти",
       x = "Грань", y = "Частота", fill = NULL) +
  theme_minimal(base_size = 12) +
  theme(legend.position = "top")
```

Кістка: спостережені vs очікувані частоти



1.5. Задача 4. Хі-квадрат узгодженості: огранки діамантів (**diamonds**)

Датасет **diamonds** (із пакета **ggplot2**, $\approx 54\,000$ діамантів) містить категорію огранки **cut**: Fair, Good, Very Good, Premium, Ideal. Припустимо, що всі п'ять огранок мають траплятися **однаково часто**. Перевірте це припущення на рівні $\alpha = 0.05$.

$$H_0: p_i = \frac{1}{5} \forall i \quad \text{проти} \quad H_a: \text{принаймні одне } p_i \neq \frac{1}{5}.$$

1.5.1. Чим ця задача відрізняється від попередньої

Метод **той самий**, але тепер вибірка велика, а реальні дані навряд чи ідеально рівномірні. Це гарна нагода побачити, як розмір вибірки впливає на висновок.

1.5.2. Розв'язання в R

Спершу подивимось на самі частоти:

```
counts <- table(diamonds$cut)
counts
```

Fair	Good	Very Good	Premium	Ideal
1610	4906	12082	13791	21551

Уже видно перекик: Ideal ($\approx 21\,500$) трапляється у понад 13 разів частіше за Fair ($\approx 1\,600$). Перевіримо формально:

```
chisq.test(counts, p = rep(1/5, 5))
```

Chi-squared test for given probabilities

```
data: counts  
X-squared = 22745, df = 4, p-value < 2.2e-16
```

1.5.3. Детальний розбір результату

Очікувана частота для кожної категорії — $54\,000/5 \approx 10\,788$. Реальні значення дуже від неї відходять, тож статистика виходить колосальною: $\hat{\chi}^2 \approx 22\,745$ при $df = 4$, а p -value практично нульове ($< 2.2 \times 10^{-16}$).


Інтерпретація. $p < 0.001 \rightarrow$ **рішуче відхиляємо H_0** . Огранки розподілені **далеко не рівномірно**: переважають Ideal та Premium, а Fair трапляється рідко.

Урок про розмір вибірки. У задачі з кісткою відхилення були випадковим шумом і тест їх «пробачив». Тут вибірка в 900 разів більша, тому навіть помірні відхилення стають надзвичайно значущими. Це нагадування: при великих даних майже будь-яке H_0 відхиляється, тож дивіться не лише на p -value, а й на **розмір** розбіжності.

```
n <- sum(counts)  
tibble(cut = names(counts),  
       Спостережено = as.integer(counts),  
       Очікувано = n / 5) |>  
  mutate(cut = factor(cut, levels = names(counts))) |>  
  pivot_longer(-cut, names_to = "type", values_to = "freq") |>  
  ggplot(aes(cut, freq, fill = type)) +  
  geom_col(position = "dodge", alpha = 0.85) +  
  geom_hline(yintercept = n / 5, linetype = "dashed", color = "grey40") +  
  scale_fill_manual(values = c("Спостережено" = "#d73027", "Очікувано" = "grey60")) +  
  scale_y_continuous(labels = label_number(big.mark = " ")) +  
  labs(title = "Огранки діамантів: рівномірність відкинуто",  
       subtitle = "Пунктир – очікувана за  $H_0$  частота",  
       x = "Огранка", y = "Кількість", fill = NULL) +  
  theme_minimal(base_size = 12) +  
  theme(legend.position = "top")
```

Огранки діамантів: рівномірність відкинуто

Пунктир — очікувана за H₀ частота



1.6. Задача 5. Хі-квадрат незалежності: стать і вид спорту

У дослідженні зв'язку між статтю та вподобанням виду спорту опитали $n = 60$ осіб:

	Футбол	Теніс	Разом
Чоловіки	20	10	30
Жінки	10	20	30
Разом	30	30	60

Чи пов'язані стать і вподобання спорту? $\alpha = 0.05$.

H_0 : ознаки незалежні проти H_a : ознаки пов'язані.

1.6.1. Математичне розв'язання

Крок 1. Очікувані частоти за незалежності. Якби стать і спорт не були пов'язані, частку любителів футболу ($30/60 = 50\%$) ми б бачили однаково серед чоловіків і жінок. Формально:

$$E_{il} = \frac{(\text{сума рядка}) \times (\text{сума стовпця})}{n} = \frac{30 \times 30}{60} = 15$$

— тобто всі чотири клітинки очікують по 15.

Крок 2. Статистика. Спостережено $\{20, 10, 10, 20\}$, очікувано всюди 15:

$$\hat{\chi}^2 = \frac{(20 - 15)^2}{15} + \frac{(10 - 15)^2}{15} + \frac{(10 - 15)^2}{15} + \frac{(20 - 15)^2}{15} = 4 \cdot \frac{25}{15} = 6.667.$$

Крок 3. Ступені свободи й критичне значення. $df = (k - 1)(m - 1) = (2 - 1)(2 - 1) = 1$, а $\chi^2_{0.95, 1} = 3.84$.

Крок 4. Рішення. $6.667 > 3.84 \rightarrow$ відхиляємо H_0 .

1.6.2. Розв'язання в R

```
tbl <- matrix(c(20, 10, 10, 20), nrow = 2, byrow = TRUE,
              dimnames = list(Стать = c("Чоловіки", "Жінки"),
                              Спорт = c("Футбол", "Теніс")))

chisq.test(tbl, correct = FALSE) # без поправки Ейтса – як у ручному розрахунку
```

Pearson's Chi-squared test

```
data:  tbl
X-squared = 6.6667, df = 1, p-value = 0.009823
```

Аргумент `correct = FALSE` вмикає поправку Ейтса, щоб результат збігся з нашим ручним розрахунком: $X^2 = 6.667$. На практиці для таблиць 2×2 радять поправку **залишати** (R вмикає її за замовчуванням):

```
chisq.test(tbl)$p.value # з поправкою Ейтса (за замовчуванням)
```

```
[1] 0.02013675
```

1.6.3. Детальний розбір результату

Інтерпретація. Без поправки: $\hat{\chi}^2 = 6.67$, $p \approx 0.010$; з поправкою Ейтса: $p \approx 0.020$. **Обидва** p -value менші за 0.05 $\rightarrow$ **відхиляємо** H_0 : стать і вподобання спорту **пов'язані**.

Зміст зв'язку видно з таблиці: чоловіки частіше обирають футбол (20 проти очікуваних 15), жінки — теніс. Поправка Ейтса трохи збільшує p -value (з 0.010 до 0.020), бо робить тест консервативнішим, але висновок не змінюється.

Чому саме 2×2 потребує поправки. При одному ступені свободи неперервний розподіл χ^2 грубо наближає дискретні частоти; поправка Ейтса компенсує це, віднімаючи 0.5 від кожного модуля відхилення, і зменшує ризик хибно «знайти» зв'язок.

1.7. Задача 6. Хі-квадрат незалежності: куріння і стать (MASS::survey)

Датасет `MASS::survey` містить результати опитування студентів університету. Перевірте, чи пов'язані **стать** (`Sex`) і **звичка курити** (`Smoke`, категорії: Never, Occas, Regul, Heavy). Побудуйте

таблицю спряженості, виконайте тест на рівні $\alpha = 0.05$, перевірте очікувані частоти й визначте, яка категорія найбільше відхиляється від незалежності.

H_0 : Sex та Smoke незалежні проти H_a : пов'язані.

1.7.1. Розв'язання в R

Будуємо таблицю спряженості (пропуски `table()` відкидає автоматично):

```
data(survey, package = "MASS")
tab <- table(survey$Sex, survey$Smoke)
tab
```

	Heavy	Never	Occas	Regul
Female	5	99	9	5
Male	6	89	10	12

Виконуємо тест:

```
test <- chisq.test(tab)
test
```

Pearson's Chi-squared test

```
data: tab
X-squared = 3.5536, df = 3, p-value = 0.3139
```

Обов'язково перевіряємо умову застосовності — очікувані частоти мають бути ≥ 5 :

```
test$expected
```

	Heavy	Never	Occas	Regul
Female	5.523404	94.4	9.540426	8.53617
Male	5.476596	93.6	9.459574	8.46383


1.7.2. Детальний розбір результату

Усі очікувані частоти ≥ 5 (найменша ≈ 5.5) — умову виконано, наближення хі-квадратом надійне. Статистика $\hat{\chi}^2 = 3.55$ при $df = (2 - 1)(4 - 1) = 3$, а $p\text{-value} \approx 0.31$.

Інтерпретація. $p \approx 0.31 > 0.05 \rightarrow$ **не відхиляємо H_0 .** Немає доказів, що інтенсивність куріння пов'язана зі статтю — у цих даних чоловіки й жінки курять приблизно в однакових пропорціях.

Яка категорія «найпідозріліша»? Навіть коли загалом зв'язку немає, корисно подивитися, де відхилення найбільші. Для цього беремо **стандартизовані залишки** Пірсона $r_{il} = (O_{il} - E_{il})/\sqrt{E_{il}}$; їхні квадрати в сумі дають $\hat{\chi}^2$, тож більший квадрат = більший внесок клітинки:

```
as.data.frame(test$residuals^2) |>
  set_names(c("Sex", "Smoke", "contrib")) |>
  ggplot(aes(Smoke, Sex, fill = contrib)) +
  geom_tile(color = "white", linewidth = 1) +
  geom_text(aes(label = round(contrib, 2)), color = "grey15", size = 5) +
  scale_fill_gradient(low = "white", high = "#d73027") +
  labs(title = "Внесок клітинок у  $\chi^2$  (квадрати стандартизованих залишків)",
       x = "Звичка курити", y = "Стать", fill = "r2") +
  theme_minimal(base_size = 12)
```



Найбільший внесок (≈ 1.47 у кожного рядка) дає категорія **Regul** (регулярне куріння): серед чоловіків регулярних курців трохи більше, ніж очікувалося б за незалежності. Але навіть найбільший доданок малий, тож сумарної $\hat{\chi}^2 = 3.55$ **недостатньо** для значущості. Це показує, як залишки допомагають побачити *структуру* відхилень, навіть коли формально H_0 не відхиляється.

2. Підсумок

№	Задача	Метод	R	Ключовий результат
1	Нормальність Setosa	Шاپіро-Вілкс	<code>shapiro.test</code>	$p = 0.46$ — нормальний

№	Задача	Метод	R	Ключовий результат
2	Нормальність Adelie	Колмогоров–Смирнов	<code>ks.test</code>	$KS\ p \approx 0.41$ vs Шапіро 0.03
3	Чесність кістки	χ^2 узгодженості	<code>chisq.test</code>	$p = 0.76$ — чесна
4	Огранки діамантів	χ^2 узгодженості	<code>chisq.test</code>	$p < 10^{-15}$ — нерівномірно
5	Стать × спорт	χ^2 незалежності	<code>chisq.test</code>	$p < 0.001$ — пов'язані
6	Стать × куріння	χ^2 незалежності	<code>chisq.test</code>	$p < 0.001$ — незалежні

Головні ідеї заняття:

1. **Тести нормальності** перевіряють *форму* неперервного розподілу. Шапіро–Вілк — потужніший (для нормальності); Колмогорова–Смирнова — універсальніший (будь-яке F_0), але менш чутливий. Завжди доповнюйте їх **Q–Q графіком**.
2. **Тести хі-квадрат** працюють із *частотами категорій*: узгодженість (один вимір проти очікуваних ймовірностей) та незалежність (таблиця спряженості двох ознак).
3. **Єдина формула** $\hat{\chi}^2 = \sum (O_i - E_i)^2 / E_i$ лежить в основі обох χ^2 -тестів; різниця лише в тому, як рахувати E_i та ступені свободи.
4. **Розмір вибірки вирішує**: задачі 3 і 4 — той самий метод, але великий n (діаманти) робить значущим навіть помірне відхилення. Дивіться на **розмір ефекту**, а не лише на p -value.
5. **Умови застосовності**: очікувані частоти $E_i \geq 5$; для таблиць 2×2 — поправка Єйтса. **Стандартизовані залишки** показують, які категорії найбільше порушують H_0 .