

Mock Midterm — розв’язання

STAT250: Теорія ймовірностей та статистика

Ihor Miroshnychenko
Kyiv School of Economics

2026-05-28

Table of contents

Як читати цей документ	3
Частина I. Теорія	3
0.1 Section A. Multiple Choice	3
0.1.a A1. Характеризація PMF	3
0.1.b A2. $\text{Var}(2X + 5)$	3
0.1.c A3. Хибне твердження про $Z \sim \mathcal{N}(0, 1)$	3
0.1.d A4. Нерівність Маркова	4
0.1.e A5. Дисперсія $\text{Binomial}(20, 0.3)$	4
0.1.f A6. Memoryless property	4
0.1.g A7. Центральна гранична теорема	5
0.1.h A8. Найсильніший лінійний зв’язок	5
0.1.i A9. Bayes — high-risk applicant	5
0.1.j A10. Закон великих чисел	6
0.2 Section B. True or False	6
0.3 Section C. Validity Check	8
0.3.a C1. $f(x) = \frac{x+1}{10}$, $x \in \{0, 1, 2, 3\}$ — валідна PMF?	8
0.3.b C2. $f(x) = \frac{x+1}{8}$, $x \in \{1, 2, 3\}$ — валідна PMF?	8
0.3.c C3. $f(x) = 3x^2$, $0 \leq x \leq 1$ — валідна PDF?	9
0.3.d C4. $f(x) = 2x$, $0 \leq x \leq 2$ — валідна PDF?	9
0.3.e C3 (бонус). Знайти k для $f(x) = k \cdot x(4 - x)$, $x \in \{1, 2, 3\}$	9
0.4 Section D. R Output Interpretation	10
0.4.a Block D1 — Normal: пісенні стріми	10
0.4.b Block D2 — Binomial: бариста	12
0.4.c Block D3 — Exponential: доставка Bolt	13
0.4.d Block D4 — Salary stats + Normal	14
Частина II. Прикладні задачі	15
0.5 Problem 1 — Spam Filter	15
0.5.a (a) Закон повної ймовірності — $P(+)$	15
0.5.b (b) Bayes — $P(S +)$	15

0.5.c	(c) Оцінка твердження «якщо фільтр зловив — точно спам»	16
0.5.d	(d) Очікувані числа з 50 листів	16
0.6	Problem 2 — DOGECAT	17
0.6.a	(a) Валідність розподілу	17
0.6.b	(b) $E[R]$ — очікувана дохідність	17
0.6.c	(c) $\text{Var}(R)$, $\text{SD}(R)$	18
0.6.d	(d) Портфель \$500	18
0.7	Problem 3 — Sleepy Barista	18
0.7.a	(a) $P(X = 0)$	18
0.7.b	(b) $P(X \geq 2)$ — правило доповнення	19
0.7.c	(c) $E[X]$, $\text{Var}(X)$	19
0.7.d	(d) Втручання менеджера — $P(X > 2)$	19
0.8	Problem 4 — Normal: Streams	20
0.8.a	(a) $P(X > 17\,000)$	20
0.8.b	(b) 90-й перцентиль ($z_{0.9} \approx 1.28$)	20
0.8.c	(c) $P(8\,000 < X < 15\,200)$	21
0.9	Problem 5 — Exponential: Delivery	22
0.9.a	(a) $E[T]$, $\text{Var}(T)$	22
0.9.b	(b) $P(T > 30)$	22
0.9.c	(c) $P(10 < T < 40)$	22
0.9.d	(d) Memoryless property: $P(T > 30 \mid T > 20)$	23
0.10	Problem 6 — Markov Inequality	23
0.10.a	(a) Формулювання + межа для $P(T \geq 900)$	23
0.10.b	(b) «Не більше 15% шансу заробити > 1200 »	23
0.10.c	(c) Розподіл, на якому межа Маркова точно	24
0.11	Problem 7 — CLT: Sleep Hours	24
0.11.a	(a) Розподіл $\bar{X}$, теорема, моменти	24
0.11.b	(b) $P(\bar{X} < 5.5)$	25
0.11.c	(c) Попир c : $P(\bar{X} > c) = 0.05$	25
0.12	Problem 8 — Joint XY: Study vs Game	25
0.12.a	(a) Маргінальні розподіли	26
0.12.b	(b) $E[X]$, $E[Y]$	26
0.12.c	(c) Незалежність	26
0.12.d	(d) $\text{Cov}(X, Y)$	27
0.13	Problem 9 — Sample Covariance & Correlation	28
0.13.a	(a) Sample covariance	28
0.13.b	(b) Sample correlation	28
0.13.c	(c) Інтерпретація	28
0.13.d	(d) «Кофе спричиняє продуктивність» — у чому хиба?	29
0.14	Problem 10 — Casino Coin Flips	29
0.14.a	(a) $E[X_i]$, $\text{Var}(X_i)$	29
0.14.b	(b) S_{100} і CLT	29

0.14.c (c) $P(S_{100} > 0)$	30
0.14.d (d) LLN і чому «грати до перемоги» приречено	30
Підсумкова таблиця відповідей	32

Як читати цей документ

Документ містить повне розв’язання **mock midterm** з курсу **STAT250 — Теорія ймовірностей та статистика** (літо 2026). Для кожного завдання спочатку наведено **математичне розв’язання**, а потім, де доречно, — **перевірку та візуалізацію в R** (tidyverse).

Частина I. Теорія

0.1 Section A. Multiple Choice

0.1.a A1. Характеризація PMF

Яка з відповідей правильно характеризує **функцію ймовірностей** (PMF)?

PMF описує **дискретну** випадкову величину. Дві обов’язкові умови:

$$p(x) \geq 0 \quad \text{для всіх } x, \quad \sum_{\text{all } x} p(x) = 1.$$

- (A) — це формула для **PDF** (інтеграл, не сума).
- (C) — PMF загалом визначена лише на зліченній множині точок.
- (D) — для PMF $p(x) = P(X = x) \leq 1$ завжди.

Правильна відповідь: (B).

0.1.b A2. $\text{Var} (2X + 5)$

$E[X] = 3, \text{Var} (X) = 4$. Знайти $\text{Var} (2X + 5)$.

Властивість дисперсії: $\text{Var} (aX + b) = a^2 \text{Var} (X)$. Зсув на константу **не змінює** розкид, а масштаб входить **квадратично**.

$$\text{Var} (2X + 5) = 2^2 \cdot 4 = 16.$$

Правильна відповідь: (C) 16.

0.1.c A3. Хибне твердження про $Z \sim \mathcal{N}(0, 1)$

Яке з тверджень про стандартний нормальний розподіл є **FALSE**?

Для будь-якої **неперервної** випадкової величини $P(Z = c) = 0$ для будь-якого фіксованого c . Отже, $P(Z = 0) = 0$, а не 0.5.

- (A) ✓ за симетрією.
- (C) ✓ — визначення $\mathcal{N}(0, 1)$.
- (D) ✓ — $\varphi(z) = \varphi(-z)$.

Правильна відповідь: (B) — це твердження хибне.

0.1.d A4. Нерівність Маркова

Для **невід'ємної** X з $E[X] = \mu$ і $a > 0$.

Класичне формулювання:

$$P(X \geq a) \leq \frac{E[X]}{a} = \frac{\mu}{a}.$$

- (C) — нерівність **Чебишева** (через дисперсію, не сподівання).
- (D) — формула виживання Ехр-розподілу, не загальне правило.

Правильна відповідь: (A).

0.1.e A5. Дисперсія Binomial(20, 0.3)

$X \sim \text{Binomial}(n = 20, p = 0.30)$. Знайти $\text{Var}(X)$.

З довідника:

$$\text{Var}(X) = np(1 - p) = 20 \cdot 0.30 \cdot 0.70 = 4.2.$$

Зауваження: $np = 6$ — це **середнє**, а $p(1 - p) = 0.21$ — дисперсія **одного** Бернуллі.

Правильна відповідь: (C) 4.2.

```
n <- 20; p <- 0.30
c(mean = n * p, variance = n * p * (1 - p), sd = sqrt(n * p * (1 - p)))
```

```
      mean variance      sd
1 6.000000  4.200000  2.04939
```

0.1.f A6. Memoryless property

Для $X \sim \text{Exp}(\lambda)$ і будь-яких $s, t > 0$.

Унікальна риса експоненційного розподілу:

$$P(X > s + t \mid X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t).$$

Тобто знання, що ми вже чекали s часу, **не змінює** розподілу майбутнього очікування.

Правильна відповідь: (A).

0.1.g A7. Центральна гранична теорема

CLT: до чого збігається $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$?

CLT **стандартизує** вибіркове середнє: ділення на $\sigma/\sqrt{n}$ і віднімання μ дає **стандартний** нормальний:

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Правильна відповідь: (B) $\mathcal{N}(0, 1)$.

0.1.h A8. Найсильніший лінійний зв'язок

Який ρ вказує на найсильніший лінійний зв'язок?

Сила лінійного зв'язку = $|\rho|$; знак — лише напрям. Серед варіантів:

$$|-0.91| = 0.91 > 0.72 > 0.50 > 0.01.$$

Від'ємний знак означає, що зі зростанням X величина Y **спадає**.

Правильна відповідь: (B) $\rho = -0.91$.

0.1.i A9. Bayes — high-risk applicant

5% високого ризику; модель ловить 90% true high-risk і **хибно** прапорить 10% low-risk.

$$P(+) = 0.05 \cdot 0.90 + 0.95 \cdot 0.10 = 0.045 + 0.095 = 0.140.$$

$$P(\text{high} \mid +) = \frac{P(+ \mid \text{high}) P(\text{high})}{P(+)} = \frac{0.05 \cdot 0.90}{0.140} = \frac{0.045}{0.140} \approx 0.321.$$

Класична base-rate fallacy: «90% чутливість» $\neq$ «90% впевненості після +», бо переважна частина «+» — це false positive з великого пулу low-risk.

Правильна відповідь: (B) ≈ 0.32 .

```
prior_h <- 0.05; prior_l <- 0.95
sens <- 0.90;   fpr <- 0.10
```

```
p_pos <- sens * prior_h + fpr * prior_l
c(p_pos = p_pos, post_high = sens * prior_h / p_pos)
```

```
p_pos post_high
0.1400000 0.3214286
```

0.1.j A10. Закон великих чисел

Що гарантує LLN при $n \rightarrow \infty$?

LLN — це твердження про **середнє за вибіркою**:

$$\bar{X}_n \xrightarrow{p} \mu.$$

- (B) — це CLT (про стандартизоване середнє).
- (C) — кожне окреме X_i залишається випадковим.
- (D) — навпаки, $S_n^2 \rightarrow \sigma^2$, не нуль.

Правильна відповідь: (A).

0.2 Section B. True or False

#	Твердження	T/F	Коментар / правильне формулювання
1	$P(A \cup B) = P(A) + P(B) - P(A \cap B)$	T	Формула включень-виключень — для будь-яких подій
2	$\text{Cov}(X, Y) = 0 \Rightarrow X \perp Y$	F	Зворотне: $X \perp Y \Rightarrow \text{Cov} = 0$. Контрприклад: $Y = X^2$ з $X \sim \mathcal{N}(0, 1)$
3	Для неперервної X і константи c : $P(X = c) = 0$	T	$\int_c^c f(x) dx = 0$
4	Дисперсія може бути від'ємною, якщо розподіл лівоскошений	F	$\text{Var}(X) = E[(X - \mu)^2] \geq 0$ завжди
5	LLN $\xrightarrow{p} \mu$ гарантує	T	Слабкий закон великих чисел (за $E X < \infty$)
6	Якщо $X \sim \mathcal{N}(\mu, \sigma^2)$, то $\frac{X - \mu}{\sigma} \sim \mathcal{N}(1, 1)$	F	Правильно: $\frac{X - \mu}{\sigma} \sim \mathcal{N}(0, 1)$ — стандартний

#	Твердження	T/F	Коментар / правильне формулювання
7	Маркова: для $X \geq 0$ і $a > 0$, $P(X \geq a) \leq E[X]/a$	T	Класичне формулювання
8	$-1 \leq \rho \leq 1$, $\rho = \pm 1 \Leftrightarrow$ ідеальний лінійний зв'язок	T	Наслідок нерівності Коші–Шварца

Контрприклад до B2 ($\text{Cov} = 0 \neq$ незалежність):

```
set.seed(2)
df <- tibble(x = rnorm(2000)) |> mutate(y = x^2)
cor(df$x, df$y)
```

```
[1] 0.06220337
```

```
df |>
  ggplot(aes(x, y)) +
  geom_point(alpha = 0.3, color = blue) +
  labs(title = "Y = X^2: cor(X, Y) ≈ 0, проте Y повністю визначається X",
        x = "X", y = "Y = X^2")
```



0.3 Section C. Validity Check

0.3.a C1. $f(x) = \frac{x+1}{10}, x \in \{0, 1, 2, 3\}$ — валідна PMF?

Невід’ємність:

$$f(0) = 0.1, f(1) = 0.2, f(2) = 0.3, f(3) = 0.4 \geq 0. \checkmark$$

Нормування:

$$\sum_{x=0}^3 \frac{x+1}{10} = \frac{1+2+3+4}{10} = \frac{10}{10} = 1. \checkmark$$

Висновок: валідна PMF.

```
x <- 0:3; pmf <- (x + 1) / 10  
tibble(x = x, p = pmf)
```

```
# A tibble: 4 × 2
```

```
      x      p  
  <int> <dbl>  
1     0  0.1  
2     1  0.2  
3     2  0.3  
4     3  0.4
```

```
sum(pmf)
```

```
[1] 1
```

0.3.b C2. $f(x) = \frac{x+1}{8}, x \in \{1, 2, 3\}$ — валідна PMF?

Невід’ємність:

$$f(1) = 0.25, f(2) = 0.375, f(3) = 0.5 \geq 0. \checkmark$$

Нормування:

$$\sum_{x=1}^3 \frac{x+1}{8} = \frac{2+3+4}{8} = \frac{9}{8} = 1.125 \neq 1. \times$$

Висновок: НЕ валідна PMF — порушено нормування. Щоб виправити: замінити знаменник на 9.

```
x <- 1:3; sum((x + 1) / 8)
```


[1] 1.125

0.3.c C3. $f(x) = 3x^2, 0 \leq x \leq 1$ — **валідна PDF?**

Невід’ємність: $3x^2 \geq 0$ для всіх x . ✓

Інтеграл:

$$\int_0^1 3x^2 dx = [x^3]_0^1 = 1. \checkmark$$

Висновок: валідна PDF (це окремий випадок $\text{Beta}(3, 1)$).

```
integrate(function(x) 3 * x^2, 0, 1)
```

1 with absolute error < 1.1e-14

0.3.d C4. $f(x) = 2x, 0 \leq x \leq 2$ — **валідна PDF?**

Невід’ємність: $2x \geq 0$ на $[0, 2]$. ✓

Інтеграл:

$$\int_0^2 2x dx = [x^2]_0^2 = 4 \neq 1. \times$$

Висновок: НЕ валідна PDF. Щоб виправити: замінити коефіцієнт 2 на $1/2$ (тоді $\int_0^2 \frac{x}{2} dx = 1$).

```
integrate(function(x) 2 * x, 0, 2)
```

4 with absolute error < 4.4e-14

0.3.e C3 (бонус). Знайти k для $f(x) = k \cdot x(4 - x), x \in \{1, 2, 3\}$

Обчислюємо суму без коефіцієнта:

$$\sum_{x=1}^3 x(4-x) = 1 \cdot 3 + 2 \cdot 2 + 3 \cdot 1 = 3 + 4 + 3 = 10.$$

Умова нормування $10k = 1$:

$$\boxed{k = \frac{1}{10} = 0.1}.$$

Перевірка невід’ємності: $0.1 \cdot \{3, 4, 3\} = \{0.3, 0.4, 0.3\} \geq 0$ ✓.

```

x <- 1:3
k <- 1 / sum(x * (4 - x))
k

[1] 0.1

tibble(x = x, p = k * x * (4 - x))

# A tibble: 3 × 2
      x     p
  <int> <dbl>
1     1  0.3
2     2  0.4
3     3  0.3

sum(k * x * (4 - x))

[1] 1

```

0.4 Section D. R Output Interpretation

0.4.a Block D1 – Normal: пісенні стріми

Контекст: $X \sim \mathcal{N}(\mu = 12, \sigma = 3.2)$ – щоденні стріми (тис.).

```

mu <- 12; sigma <- 3.2
pnorm(15.2, mu, sigma)          # 0.8413

[1] 0.8413447

pnorm(8.8, mu, sigma)           # 0.1587

[1] 0.1586553

pnorm(5.6, mu, sigma, lower.tail = FALSE) # 0.9772

[1] 0.9772499

```

```
qnorm(0.90, mu, sigma) # 16.10
```

```
[1] 16.10097
```

D1(a) pnorm(15.2) = 0.8413.

$$P(X < 15.2) = 0.8413 \approx 84.13\%.$$

Близько **84%** пісень отримують менше 15 200 стрімів на день. Поріг $15.2 = \mu + \sigma$ (тобто $z = 1$). Для продюсера: 15 200 — це **верхня межа звичайного діапазону**, не «хіт».

D1(b) Правило 68–95–99.7.

$$P(8.8 < X < 15.2) = 0.8413 - 0.1587 = 0.6826.$$

Інтервал $[8.8; 15.2] = [\mu - \sigma; \mu + \sigma]$ — це класичне правило $\mu \pm 1\sigma$: 68.27% маси у межах одного стандартного відхилення.

D1(c) pnorm(5.6, lower.tail = FALSE) = 0.9772.

$$P(X > 5.6) = 0.9772, \text{ еквівалентно } P(X < 5.6) = 0.0228.$$


Поріг $5.6 = \mu - 2\sigma$ ($z = -2$). Лише $\approx 2.3\%$ пісень отримують менше 5 600 стрімів — це сильний сигнал, що пісня **серйозно недопрацьовує** (нижні 2.5%).

D1(d) qnorm(0.90) = 16.10.

Поріг «хіта» — **16 100 стрімів** (90-й перцентиль). Геометрично: точка на осі x , **лівіше** від якої лежить 90% площі під кривою; справа залишається 10% — це і є «хіти». Зауваження: $16.10 > \mu + \sigma = 15.2$, бо $z_{0.9} = 1.282 > 1$.

```
xs <- seq(mu - 4*sigma, mu + 4*sigma, length.out = 600)
in_band <- tibble(x = seq(mu - sigma, mu + sigma, length.out = 200)) |>
  mutate(y = dnorm(x, mu, sigma))

ggplot(tibble(x = xs, y = dnorm(xs, mu, sigma)), aes(x, y)) +
  geom_area(data = in_band, fill = blue, alpha = 0.35) +
  geom_line(color = grey_d, linewidth = 0.8) +
  geom_vline(xintercept = c(5.6, 16.10),
             color = c(red, green), linetype = "dotted", linewidth = 0.9) +
  annotate("text", x = 5.6, y = 0.025, label = "5.6 = μ - 2σ",
           color = red, hjust = -0.05) +
  annotate("text", x = 16.10, y = 0.04, label = "16.10 = 90-й перцентиль",
           color = green, hjust = -0.05) +
  labs(title = "X ~ N(12, 3.2²): пороги недопрацювання та «хіта»",
       x = "Стріми (тис.)", y = "Щільність")
```



0.4.b Block D2 — Binomial: бариста

$X \sim \text{Binomial}(10, 0.12)$.

```
dbinom(0, 10, 0.12) # 0.2785
```

```
[1] 0.278501
```

```
pbinom(1, 10, 0.12) # 0.6583
```

```
[1] 0.658275
```

```
1 - pbinom(2, 10, 0.12) # 0.1087
```

```
[1] 0.1086818
```

D2(a) `dbinom(0) = 0.2785`.

$$P(X = 0) = 0.88^{10} \approx 0.2785.$$

Ймовірність «ідеальної зміни» — жодної помилки за 10 замовлень. **Так**, це ймовірність «доброї зміни», але лише $\approx 28\%$ змін такими бувають.

D2(b) `pbinom(1) = 0.6583`.

$$P(X \leq 1) = P(X = 0) + P(X = 1) = 0.6583.$$

Подія: **не більше 1 помилки** за 10 замовлень. Включаються обидва значення $X = 0$ та $X = 1$ (нотація `rbinom` дає $\leq$).

D2(c) 1 - `rbinom(2) = 0.1087`.

$$P(X > 2) = P(X \geq 3) = 1 - P(X \leq 2) = 0.1087.$$

Менеджер втручається у $\approx 10.9\%$ змін — приблизно одна з дев'яти.

D2(d) Різниця між двома кумулятивами.

- `rbinom(1, ...)` = $P(X \leq 1)$ — кумулює **малі** значення (тихі, успішні зміни).
- `1 - rbinom(2, ...)` = $P(X \geq 3)$ — **верхній хвіст** (поганий результат).

Чому величини різні (0.66 vs 0.11)? При $p = 0.12$ розподіл сильно скошений до малих значень: $E[X] = np = 1.2$. Маса сконцентрована в $\{0, 1, 2\}$, у хвості ≥ 3 маси мало.

0.4.c Block D3 — Exponential: доставка Bolt

$T \sim \text{Exp}(\lambda = 1/20)$, $E[T] = 20$ хв.

```
pexp(30, rate = 1/20, lower.tail = FALSE)      # 0.2231
```

```
[1] 0.2231302
```

```
pexp(40, rate = 1/20) - pexp(10, rate = 1/20)  # 0.4712
```

```
[1] 0.4711954
```

```
qexp(0.50, rate = 1/20)                        # 13.86
```

```
[1] 13.86294
```

```
qexp(0.95, rate = 1/20)                        # 59.91
```

```
[1] 59.91465
```

D3(a) `pexp(30, lower=F) = 0.2231`.

$$P(T > 30) = e^{-30/20} = e^{-1.5} \approx 0.2231.$$

Близько 22.3% доставок займають довше 30 хв — кожна п'ята доставка «довга».

D3(b) `pexp(40) - pexp(10) = 0.4712`.

$$P(10 < T < 40) = e^{-10/20} - e^{-40/20} \approx 0.6065 - 0.1353 = 0.4712.$$

Подія: доставка прийшла в «прийнятному вікні» від 10 до 40 хвилин. $\approx 47\%$ усіх доставок.

D3(c) Медіана 13.86 < середнє 20.

Для Exp:

$$\text{Median} = \frac{\ln 2}{\lambda} \approx 0.693 \cdot E[T] < E[T].$$

Що це означає про форму: розподіл **скошений вправо** (right-skewed). Кілька дуже довгих доставок «тягнуть» середнє вгору, а медіана залишається ближче до типового досвіду.

D3(d) qexp(0.95) = 59.91.

$X = 59.91$ хв — «95% доставок прибувають за ≤ 60 хв». Для клієнта о 2 ночі: з 5% ймовірністю чекати доведеться **довше години** — варто врахувати, якщо ви дуже голодні.

0.4.d Block D4 — Salary stats + Normal

```
summary(salary)
# Min. 1st Qu. Median Mean 3rd Qu. Max.
# 2100 3800 4900 5600 6200 42000
sd(salary) # [1] 3200
pnorm(3800, 5600, 3200) # 0.2869
pnorm(9000, 5600, 3200, lower.tail = F) # 0.1440
```

D4(a) Форма розподілу.

Mean (5600) > Median (4900), Max (42 000) сильно віддалений від $Q_3 = 6200$. Класичні ознаки **сильної правої скошеності**: кілька високооплачуваних топ-менеджерів тягнуть середнє вгору.

Нормальний — поганий фіт: симетричний, тонкохвостий, не моделює викиди. Краще log-normal або gamma.

D4(b) pnorm(3800) = 0.2869.

За нормальною апроксимацією $\approx 29\%$ співробітників заробляють менше \$3 800/міс. Реальна частка може відрізнятись через скошеність.

D4(c) pnorm(9000, lower=F) = 0.1440.

Під нормальною моделлю $\approx 14.4\%$ — топ-заробляючі (> \$9000). Через важкий правий хвіст реальний відсоток може бути **меншим** (мало людей, але вони далеко відриваються).

D4(d) «Більшість заробляє вище середнього».

Релевантна статистика — медіана, не середнє.

- Median = 4 900: рівно половина людей заробляє **менше \$4 900**.
- Mean = 5 600: половина < 4 900, тобто > 50% заробляє **менше середнього \$5 600**.

Менеджер помиляється: при правій скошеності типова людина заробляє **менше** середнього. Це фундаментальна риса несиметричних розподілів зарплат.

Частина II. Прикладні задачі

0.5 Problem 1 — Spam Filter

Дано:

Подія	Позначення	Значення
Частка спаму	$P(S)$	0.20
Чутливість (TPR)	$P(+ S)$	0.95
Хибнопозитивний (FPR)	$P(+ \bar{S})$	0.08

```
prior_s <- 0.20; prior_ns <- 0.80
sens <- 0.95; fpr <- 0.08
спес <- 1 - fpr
```

0.5.a (a) Закон повної ймовірності — $P(+)$

$$P(+) = P(+ | S)P(S) + P(+ | \bar{S})P(\bar{S}) = 0.95 \cdot 0.20 + 0.08 \cdot 0.80$$

$$= 0.19 + 0.064 = \boxed{0.254}.$$

```
p_pos <- sens * prior_s + fpr * prior_ns
p_pos
```

```
[1] 0.254
```

0.5.b (b) Bayes — $P(S | +)$

$$P(S | +) = \frac{P(+ | S) P(S)}{P(+)} = \frac{0.95 \cdot 0.20}{0.254} = \frac{0.19}{0.254} \approx \boxed{0.748}.$$

Близько **75%** позначених листів дійсно є спамом.

```
p_s_given_pos <- sens * prior_s / p_pos
p_s_given_pos
```

[1] 0.7480315

0.5.c (c) Оцінка твердження «якщо фільтр зловив — точно спам»

Це **хибне** твердження: $P(S | +) = 0.748$, не 1. Один з кожних **чотирьох** позначених листів — насправді **легітимний** (false positive).

Чому: легітимних листів у 4 рази більше (80% vs 20%), тож навіть 8% помилкових прапорів дають значний абсолютний внесок: 0.064 проти 0.19. Завжди перевіряйте папку «Спам».

0.5.d (d) Очікувані числа з 50 листів

$$E[\# \text{ spam}] = 50 \cdot 0.20 = 10.$$

З них фільтр правильно позначає:


$$E[\# \text{ true positive}] = 10 \cdot 0.95 = 9.5.$$

У середньому з 50 листів **10 будуть спамом** і фільтр **правильно зловить $\approx 9 - 10$** з них.

```
c(spam = 50 * prior_s, tp = 50 * prior_s * sens)
```

```
spam  tp
10.0  9.5
```

```
N <- 1000
tibble(class = c("Spam", "Spam", "Ham", "Ham"),
       flag = c("+", "-", "+", "-"),
       n     = c(N * prior_s * sens, N * prior_s * (1 - sens),
                 N * prior_ns * fpr, N * prior_ns * (1 - fpr))) |>
  ggplot(aes(flag, n, fill = class)) +
  geom_col(width = 0.6) +
  geom_text(aes(label = round(n)),
            position = position_stack(vjust = 0.5), color = "white") +
  scale_fill_manual(values = c("Spam" = red, "Ham" = blue)) +
  labs(title = "1000 листів: 254 «+», з них 190 — спам, 64 — false positive",
       x = "Прапор фільтра", y = "Кількість листів", fill = NULL)
```

0.6 Problem 2 — DOGECAT

Сценарій	Rug pull	Crabbing	To the moon
Доходність r	-40%	+5%	+60%
$P(R = r)$	0.50	0.30	0.20

```
r <- c(-0.40, 0.05, 0.60)
p <- c(0.50, 0.30, 0.20)
```

0.6.a (a) Валідність розподілу

Невід'ємність: $0.50, 0.30, 0.20 \geq 0 \checkmark$

Сума: $0.50 + 0.30 + 0.20 = 1.00 \checkmark$

Висновок: валідний дискретний розподіл.

0.6.b (b) $E[R]$ — очікувана доходність

$$E[R] = -0.40 \cdot 0.50 + 0.05 \cdot 0.30 + 0.60 \cdot 0.20 = -0.20 + 0.015 + 0.12$$

$$= \boxed{-0.065 = -6.5\%}.$$

Очікувана доходність **від'ємна** $\rightarrow$ це **погана** «інвестиція»: у середньому втрачаємо 6.5% капіталу на місяць.

```
ER <- sum(r * p); ER
```

[1] -0.065

0.6.c (c) $\text{Var}(R), \text{SD}(R)$

$$E[R^2] = 0.16 \cdot 0.50 + 0.0025 \cdot 0.30 + 0.36 \cdot 0.20 = 0.080 + 0.00075 + 0.072 = 0.15275.$$

$$\text{Var}(R) = 0.15275 - (-0.065)^2 = 0.15275 - 0.004225 = 0.148525.$$

$$\text{SD}(R) = \sqrt{0.148525} \approx \boxed{0.3854 = 38.5\%}.$$

$\text{SD} \approx 39\%$ — гігантська волатильність порівняно з середнім -6.5% : актив більше нагадує **казино**, ніж інвестицію.

```
VarR <- sum(r^2 * p) - ER^2
c(Var = VarR, SD = sqrt(VarR))
```

```
      Var      SD
0.1485250 0.3853894
```

0.6.d (d) Портфель \$500

Портфель $V = 500 \cdot (1 + R) = 500 + 500R$.

$$E[V] = 500 + 500 \cdot E[R] = 500 - 32.50 = \boxed{\$467.50}.$$

$$\text{SD}(V) = 500 \cdot \text{SD}(R) \approx 500 \cdot 0.3854 \approx \boxed{\$192.7}.$$

```
EV <- 500 * (1 + ER)
SDV <- 500 * sqrt(VarR)
c(E_V = EV, SD_V = SDV)
```

```
      E_V      SD_V
467.5000 192.6947
```

0.7 Problem 3 — Sleepy Barista

$X \sim \text{Binomial}(n = 10, p = 0.12)$.

0.7.a (a) $P(X = 0)$

$$P(X = 0) = \binom{10}{0} (0.12)^0 (0.88)^{10} = 0.88^{10} \approx \boxed{0.2785}.$$

```
dbinom(0, 10, 0.12)
```

```
[1] 0.278501
```

0.7.b (b) $P(X \geq 2)$ – правило доповнення

$$P(X = 1) = 10 \cdot 0.12 \cdot 0.88^9 \approx 0.3798.$$

$$P(X \geq 2) = 1 - P(X = 0) - P(X = 1) = 1 - 0.2785 - 0.3798 \approx \boxed{0.3417}.$$

```
1 - pbinom(1, 10, 0.12)
```

```
[1] 0.341725
```

0.7.c (c) $E[X]$, $\text{Var}(X)$

$$E[X] = np = 1.2, \quad \text{Var}(X) = np(1 - p) = 1.056.$$

Інтерпретація: у середньому за зміну з 10 замовлень буде **1.2 неправильних** – приблизно одне.

0.7.d (d) Втручання менеджера – $P(X > 2)$

$$P(X > 2) = P(X \geq 3) = 1 - P(X \leq 2) \approx \boxed{0.1087}.$$

Менеджер втручається приблизно у **1 з 9** змін.

```
1 - pbinom(2, 10, 0.12)
```

```
[1] 0.1086818
```

```
tibble(k = 0:10, pmf = dbinom(0:10, 10, 0.12)) |>
  mutate(zone = case_when(k <= 1 ~ "≤ 1",
                           k == 2 ~ "= 2",
                           k >= 3 ~ "≥ 3 (втручання)")) |>
  ggplot(aes(k, pmf, fill = zone)) +
  geom_col(width = 0.7) +
  scale_fill_manual(values = c("≤ 1" = blue, "= 2" = grey_l, "≥ 3 (втручання)"
                                = red)) +
  scale_x_continuous(breaks = 0:10) +
  labs(title = "Binom(10, 0.12): зони ймовірностей",
       x = "k неправильних замовлень", y = "P(X = k)", fill = NULL)
```



0.8 Problem 4 — Normal: Streams

$X \sim \mathcal{N}(\mu = 12\,000, \sigma = 3\,200)$.

0.8.a (a) $P(X > 17\,000)$

$$z = \frac{17\,000 - 12\,000}{3\,200} = 1.5625.$$

$$P(X > 17\,000) = 1 - \Phi(1.5625) \approx 1 - 0.9410 = \boxed{0.0590}.$$

Близько 5.9% пісень отримують понад 17 тис. стрімів.

```
1 - pnorm(17000, 12000, 3200)
```

```
[1] 0.05908512
```

0.8.b (b) 90-й перцентиль ($z_{0.9} \approx 1.28$)

$$x_{0.9} = \mu + z_{0.9} \cdot \sigma = 12\,000 + 1.28 \cdot 3\,200 = \boxed{16\,096}.$$

10% найкращих пісень отримують щонайменше $\approx 16\,100$ стрімів на день.

```
qnorm(0.90, 12000, 3200)
```

```
[1] 16100.97
```

0.8.c (c) $P(8\,000 < X < 15\,200)$

$$z_1 = \frac{8\,000 - 12\,000}{3\,200} = -1.25, \quad z_2 = \frac{15\,200 - 12\,000}{3\,200} = 1.$$


$$P = \Phi(1) - \Phi(-1.25) = 0.8413 - 0.1056 = \boxed{0.7357}.$$

```
pnorm(15200, 12000, 3200) - pnorm(8000, 12000, 3200)
```

```
[1] 0.735695
```

```
mu_s <- 12000; sigma_s <- 3200
xs <- seq(mu_s - 4*sigma_s, mu_s + 4*sigma_s, length.out = 600)
band <- tibble(x = seq(8000, 15200, length.out = 200)) |>
  mutate(y = dnorm(x, mu_s, sigma_s))

ggplot(tibble(x = xs, y = dnorm(xs, mu_s, sigma_s)), aes(x, y)) +
  geom_area(data = band, fill = blue, alpha = 0.4) +
  geom_line(color = grey_d, linewidth = 0.8) +
  geom_vline(xintercept = 17000, color = red, linetype = "dashed", linewidth =
1) +
  geom_vline(xintercept = qnorm(0.9, mu_s, sigma_s),
            color = green, linetype = "dotted", linewidth = 1) +
  annotate("text", x = 17000, y = 1e-4, label = "17 000 (5.9%)",
            color = red, hjust = -0.05) +
  annotate("text", x = qnorm(0.9, mu_s, sigma_s), y = 8e-5, label = "90-
й перцентиль",
            color = green, hjust = -0.05) +
  labs(title = "N(12 000, 3 200²): пороги та вікно P(8 000 < X < 15 200) = 0.7357",
        x = "Стріми", y = "Щільність")
```



0.9 Problem 5 – Exponential: Delivery

$T \sim \text{Exp}(\lambda)$, $1/\lambda = 20 \text{ хв} \Rightarrow \lambda = 0.05$.

0.9.a (a) $E[T]$, $\text{Var}(T)$

$$E[T] = \frac{1}{\lambda} = 20 \text{ хв},$$

$$\text{Var}(T) = \frac{1}{\lambda^2} = 400 \text{ хв}^2, \quad \text{SD}(T) = 20 \text{ хв}.$$

Характерна риса Exp: $\text{SD}(T) = E[T]$.

0.9.b (b) $P(T > 30)$

$$P(T > 30) = e^{-30/20} = e^{-1.5} \approx \boxed{0.2231}.$$

1 - `rexp(30, 1/20)`

[1] 0.2231302

0.9.c (c) $P(10 < T < 40)$

$$P(10 < T < 40) = e^{-10/20} - e^{-40/20} = e^{-0.5} - e^{-2} \approx 0.6065 - 0.1353 = \boxed{0.4712}.$$

`rexp(40, 1/20) - rexp(10, 1/20)`

[1] 0.4711954

0.9.d (d) Memoryless property: $P(T > 30 \mid T > 20)$

$$P(T > 30 \mid T > 20) = \frac{P(T > 30)}{P(T > 20)} = \frac{e^{-1.5}}{e^{-1}} = e^{-0.5}$$
$$= P(T > 10) \approx \boxed{0.6065}.$$

Інтерпретація. Факт того, що студент уже дочекав 20 хв, **не дає жодної інформації** про подальший час очікування. Розподіл «забуває» минуле — інтуїція «зараз має приїхати» тут хибна.

```
# Перевірка рівності двох ймовірностей  
(1 - rexp(30, 1/20)) / (1 - rexp(20, 1/20))
```

```
[1] 0.6065307
```

```
1 - rexp(10, 1/20)
```

```
[1] 0.6065307
```

0.10 Problem 6 — Markov Inequality

$T \geq 0$ — чайові кур'єра (UAH), $E[T] = 180$.

0.10.a (a) Формулювання + межа для $P(T \geq 900)$

Умови: $X \geq 0$, $E[X] < \infty$, $a > 0$.

Нерівність Маркова:

$$P(X \geq a) \leq \frac{E[X]}{a}.$$

Застосування ($a = 900$):

$$P(T \geq 900) \leq \frac{180}{900} = 0.20 = \boxed{20\%}.$$

0.10.b (b) «Не більше 15% шансу заробити > 1200»

За Марковим:

$$P(T \geq 1200) \leq \frac{180}{1200} = 0.15 = 15\%.$$

Маркова дає **верхню межу** 15% — рівно стільки, скільки заявив друг. Тобто його твердження **валідне** (не суперечить Маркову) і точно збігається з межею. Реальна ймовірність може бути значно меншою (навіть 0%), але **не може перевищити** 15%.

0.10.c (c) Розподіл, на якому межа Маркова точна

Маркова досягається, коли вся маса зосереджена в **двох точках**: 0 та a .

Конкретний приклад:

$$P(T = 900) = 0.20, \quad P(T = 0) = 0.80.$$

Перевірка:

- $E[T] = 0 \cdot 0.80 + 900 \cdot 0.20 = 180 \checkmark$
- $P(T \geq 900) = 0.20$ — точно дорівнює межі $E[T]/900 \checkmark$

Урок: Маркова **груба** для розподілів із багатою структурою, але **точно** для двозначкових. Якщо знаємо Var, можна суттєво поліпшити через **Чебишева**.

```
# Двозначковий приклад, де Markov точна
T_vals <- c(0, 900); T_p <- c(0.8, 0.2)
sum(T_vals * T_p)           # E[T] = 180

[1] 180

sum(T_p[T_vals >= 900])    # P(T >= 900) = 0.20 — рівно як Markov

[1] 0.2
```

0.11 Problem 7 — CLT: Sleep Hours

$\mu = 5.8$ год, $\sigma = 1.2$ год, $n = 36$, розподіл невідомий.

0.11.a (a) Розподіл $\bar{X}$, теорема, моменти

За Центральною граничною теоремою (бо $n = 36 \geq 30$):

$$\bar{X} \stackrel{\text{прибл.}}{\sim} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

$$E[\bar{X}] = \mu = 5.8 \text{ год},$$

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n} = \frac{1.44}{36} = 0.04, \quad \text{SE}(\bar{X}) = 0.2 \text{ год}.$$

$$\boxed{\bar{X} \stackrel{\text{прибл.}}{\sim} \mathcal{N}(5.8, 0.2^2)}.$$

0.11.b (b) $P(\bar{X} < 5.5)$

$$z = \frac{5.5 - 5.8}{0.2} = -1.5.$$

$$P(\bar{X} < 5.5) = \Phi(-1.5) = 1 - 0.9332 = \boxed{0.0668}.$$

Близько **6.7%** ймовірність того, що середній сон у вибірці з 36 студентів буде нижчий 5.5 год.

```
pnorm(5.5, 5.8, 0.2)
```

```
[1] 0.0668072
```

0.11.c (c) Попір c : $P(\bar{X} > c) = 0.05$

$$c = \mu + z_{0.95} \cdot \text{SE} = 5.8 + 1.645 \cdot 0.2 = \boxed{6.129 \text{ год}}.$$

Лише в 5% вибірок із 36 студентів середній сон перевищить **6.13 год**.

```
qnorm(0.95, 5.8, 0.2)
```

```
[1] 6.128971
```

0.12 Problem 8 — Joint XY: Study vs Game

$X \setminus Y$	$Y = 0$	$Y = 2$	$Y = 4$
$X = 1$	0.05	0.15	0.10
$X = 3$	0.10	0.25	0.15
$X = 6$	0.15	0.05	0.00

```
joint <- matrix(c(0.05, 0.15, 0.10,  
                 0.10, 0.25, 0.15,  
                 0.15, 0.05, 0.00),  
               nrow = 3, byrow = TRUE,  
               dimnames = list(X = c(1, 3, 6), Y = c(0, 2, 4)))  
sum(joint) # перевірка нормування
```

```
[1] 1
```

0.12.a (a) Маргінальні розподіли

За рядками (підсумовуємо по Y):

$$P(X = 1) = 0.30, \quad P(X = 3) = 0.50, \quad P(X = 6) = 0.20.$$

За стовпцями (підсумовуємо по X):

$$P(Y = 0) = 0.30, \quad P(Y = 2) = 0.45, \quad P(Y = 4) = 0.25.$$

```
px <- rowSums(joint); py <- colSums(joint)
list(px = px, py = py)
```

```
$px
  1   3   6
0.3 0.5 0.2
```

```
$py
  0   2   4
0.30 0.45 0.25
```

0.12.b (b) $E[X], E[Y]$

$$E[X] = 1 \cdot 0.30 + 3 \cdot 0.50 + 6 \cdot 0.20 = 0.30 + 1.50 + 1.20 = \boxed{3.0}.$$

$$E[Y] = 0 \cdot 0.30 + 2 \cdot 0.45 + 4 \cdot 0.25 = 0 + 0.90 + 1.00 = \boxed{1.9}.$$

```
xs <- c(1, 3, 6); ys <- c(0, 2, 4)
EX <- sum(xs * px); EY <- sum(ys * py)
c(EX = EX, EY = EY)
```

```
EX EY
3.0 1.9
```

0.12.c (c) Незалежність

Перевіряємо клітинку ($X = 1, Y = 0$):

$$P(X = 1) P(Y = 0) = 0.30 \cdot 0.30 = 0.09.$$

$$P(X = 1, Y = 0) = 0.05 \neq 0.09.$$

X і Y не є незалежними. Інтуїція: хто більше вчиться, той менше грає (клітинка (6, 4) має ймовірність 0).

```
outer(px, py) - joint # ненульова матриця -> залежність
```

	0	2	4
1	0.04	-0.015	-0.025
3	0.05	-0.025	-0.025
6	-0.09	0.040	0.050

0.12.d (d) Cov (X, Y)

$$E[XY] = \sum_{x,y} xy \cdot P(x, y).$$

```
EXY <- sum(outer(xs, ys) * joint)
EXY
```

```
[1] 4.6
```


```
Cov_XY <- EXY - EX * EY
Cov_XY
```

```
[1] -1.1
```

$$E[XY] = 4.9, \quad \text{Cov}(X, Y) = E[XY] - E[X]E[Y] = 4.9 - 3.0 \cdot 1.9 = 4.9 - 5.7 = \boxed{-0.80}.$$

Знак: від'ємний $\rightarrow$ ті, хто більше вчаться, грають **менше** (і навпаки). Це логічно: час за день обмежений.

```
expand_grid(X = xs, Y = ys) |>
  mutate(p = as.vector(t(joint))) |>
  ggplot(aes(factor(Y), factor(X), fill = p)) +
  geom_tile(color = "white") +
  geom_text(aes(label = scales::number(p, 0.01)), size = 4.5) +
  scale_fill_gradient(low = "white", high = blue) +
  labs(title = "Joint розподіл: Cov(X, Y) = -0.80",
       x = "Y (години гри)", y = "X (години навчання)", fill = "P")
```



0.13 Problem 9 – Sample Covariance & Correlation

$n = 25$, $\bar{X} = 2.8$, $\bar{Y} = 64.0$, $S_X = 1.1$, $S_Y = 12.5$, $\sum (X_i - \bar{X})(Y_i - \bar{Y}) = 154.0$.

0.13.a (a) Sample covariance

$$S_{XY} = \frac{1}{n-1} \sum (X_i - \bar{X})(Y_i - \bar{Y}) = \frac{154.0}{24} \approx \boxed{6.4167}.$$

```
S_XY <- 154 / (25 - 1); S_XY
```

```
[1] 6.416667
```

0.13.b (b) Sample correlation

$$r_{XY} = \frac{S_{XY}}{S_X \cdot S_Y} = \frac{6.4167}{1.1 \cdot 12.5} = \frac{6.4167}{13.75} \approx \boxed{0.467}.$$

```
r_XY <- S_XY / (1.1 * 12.5); r_XY
```

```
[1] 0.4666667
```

0.13.c (c) Інтерпретація

Знак: додатний — більше кави корелює з вищою самооцінкою продуктивності.

Сила: $|r| \approx 0.47$ — **помірний** лінійний зв'язок.

Орієнтовна шкала:

$ r $	Сила
0.0–0.2	дуже слабкий
0.2–0.4	слабкий
0.4–0.6	помірний ← наш випадок
0.6–0.8	сильний
0.8–1.0	дуже сильний

0.13.d (d) «Кофе спричиняє продуктивність» — у чому хиба?

$r = 0.47$ показує лише лінійну асоціацію, не каузальність.

Альтернативні пояснення:

1. **Зворотна каузальність:** більш мотивовані/продуктивні люди п'ють більше кави.
2. **Сторонній фактор (confounder):** обидві змінні залежать, скажімо, від **тиску дедлайнів** — більше дедлайнів $\rightarrow$ більше і кави, і зусиль.
3. **Самооцінка $\neq$ продуктивність:** Y — суб'єктивна, корелює радше з настроєм/ентузіазмом.

Для каузальних висновків потрібен **експеримент** (RCT) або принаймні квазі-експериментальний дизайн.

0.14 Problem 10 — Casino Coin Flips

$X_i = +100$ з ймов. 0.45, -100 з ймов. 0.55, флипи незалежні.

0.14.a (a) $E[X_i]$, $\text{Var}(X_i)$

$$E[X_i] = 100 \cdot 0.45 + (-100) \cdot 0.55 = 45 - 55 = -10.$$

$$E[X_i^2] = 100^2 \cdot 0.45 + 100^2 \cdot 0.55 = 10\,000.$$

$$\text{Var}(X_i) = 10\,000 - (-10)^2 = \boxed{9\,900}.$$

$E[X_i] = -\$10$ — **математика на боці казино** (експлуатує перевагу 0.55 проти 0.45).

0.14.b (b) S_{100} і CLT

За незалежністю флипів:

$$E[S_{100}] = 100 \cdot (-10) = -1\,000.$$

$$\text{Var}(S_{100}) = 100 \cdot 9\,900 = 990\,000, \quad \text{SD}(S_{100}) = \sqrt{990\,000} \approx 995.$$

Теорема: Центральна гранична теорема (CLT). Для $n = 100$:

$$S_{100} \overset{\text{прибл.}}{\sim} \mathcal{N}(-1\,000, 995^2).$$

0.14.c (c) $P(S_{100} > 0)$

$$z = \frac{0 - (-1000)}{995} \approx 1.005.$$

$$P(S_{100} > 0) = 1 - \Phi(1.005) \approx 1 - 0.8425 = \boxed{0.1575}.$$

Близько 15.7% шанс закінчити «у плюсі» після 100 фліпів.

```
1 - pnorm(0, mean = -1000, sd = sqrt(990000))
```

```
[1] 0.1574393
```

0.14.d (d) LLN і чому «грати до перемоги» приречено

Закон великих чисел:

$$\bar{X}_n = \frac{S_n}{n} \xrightarrow{p} E[X_i] = -\$10.$$

Тобто **середній виграш на фліп** збігається до $-\$10$ — не до 0 і не до додатного числа.

Чому «грати до перемоги» приречено:

- $E[S_n] = -10n \rightarrow$ лінійно **зростає вниз** із n .
- $SD(S_n) = 99.5\sqrt{n} \rightarrow$ росте, але **повільніше** ($\sqrt{n}$ проти n).
- Відношення $\frac{|E[S_n]|}{SD(S_n)} = \frac{10\sqrt{n}}{99.5} \rightarrow \infty$.

Тому $P(S_n > 0) \rightarrow 0$ при $n \rightarrow \infty$ — чим довше граєш, тим **меншою** стає ймовірність вийти в нуль. LLN не дає «реваншу» — він **гарантує** збитки на дистанції. Це і є **edge of the house**.

Симуляційна перевірка.

```
set.seed(42)
sim <- replicate(20000, sum(sample(c(100, -100), 100,
                                   replace = TRUE, prob = c(0.45, 0.55))))
c(mean = mean(sim), sd = sd(sim), `P(S>0)` = mean(sim > 0))
```


mean	sd	P(S>0)
-992.30000	994.75132	0.13545

```
tibble(s = sim) |>
  ggplot(aes(s)) +
  geom_histogram(aes(y = after_stat(density)),
                 bins = 50, fill = blue, alpha = 0.5, color = "white") +
```

```

stat_function(fun = dnorm, args = list(mean = -1000, sd = 995),
             color = red, linewidth = 1) +
geom_vline(xintercept = 0, color = green, linetype = "dashed", linewidth =
0.8) +
annotate("text", x = 200, y = 0.0003,
        label = paste0("P(S>0) ≈ ", percent(mean(sim > 0), 0.1)),
        color = green, hjust = 0) +
labs(title = "S1000: симуляція vs CLT-наближення N(-1000, 9952)",
     x = "Сумарний виграш, $", y = "Щільність")


```



```

set.seed(11)
draws <- sample(c(100, -100), 5000, replace = TRUE, prob = c(0.45, 0.55))
tibble(n = seq_along(draws),
      cum_mean = cumsum(draws) / seq_along(draws)) |>
ggplot(aes(n, cum_mean)) +
geom_line(color = blue) +
geom_hline(yintercept = -10, color = red, linetype = "dashed", linewidth =
1) +
annotate("text", x = 4500, y = -3, label = "E[X] = -10", color = red) +
labs(title = "LLN: середній виграш на фліп збігається до -$10",
     x = "n фліпів", y = expression(bar(X)[n]))

```



Підсумкова таблиця відповідей

Завдання	Відповідь	Бали
A1	(B) PMF: $p \geq 0, \sum p = 1$	1
A2	(C) 16	1
A3	(B) $P(Z = 0) = 0.5$ — хибно	1
A4	(A) $P(X \geq a) \leq \mu/a$	1
A5	(C) 4.2	1
A6	(A) memoryless	1
A7	(B) $\mathcal{N}(0, 1)$	1
A8	(B) $\rho = -0.91$	1
A9	(B) ≈ 0.32	1
A10	(A) $\bar{X}_n \xrightarrow{p} \mu$	1
B1	T	1
B2	F $\rightarrow$ правильно: незалежність $\Rightarrow$ Cov = 0	1
B3	T	1
B4	F $\rightarrow$ Var (X) ≥ 0 завжди	1
B5	T	1
B6	F $\rightarrow \sim \mathcal{N}(0, 1)$	1

Завдання	Відповідь	Бали
B7	T	1
B8	T	1
C1	Валідна PMF ✓	1.5
C2	НЕ валідна (сума = 9/8)	1.5
C3	Валідна PDF ✓	1.5
C4	НЕ валідна (інтеграл = 4)	1.5
C-bonus	$k = 1/10$	+2
D1(a)	84%; $15.2 = \mu + \sigma$	1
D1(b)	Правило 68%; $\mu \pm \sigma$	1
D1(c)	$P(X > 5.6) = 0.9772$; $5.6 = \mu - 2\sigma$	1
D1(d)	16 100 – 90-й перцентиль	1
D2(a)	$P(X = 0) = 0.2785$ – «ідеальна зміна»	1
D2(b)	$P(X \leq 1) = 0.6583$, обидва значення включені	1
D2(c)	$P(X > 2) = 0.1087$ – втручання	1
D2(d)	Лівий кумулятив vs правий хвіст	1
D3(a)	22.3% доставок > 30 хв	1
D3(b)	$P(10 < T < 40) = 0.4712$	1
D3(c)	Right-skewed: median < mean	1
D3(d)	59.91 хв – 95-й перцентиль	1
D4(a)	Right-skewed; нормальний – поганий фіт	1
D4(b)	$\approx 29\%$ заробляють < \$3800	1
D4(c)	$\approx 14.4\%$ – топ-заробляючі	1
D4(d)	Релевантна – медіана ; менеджер помиляється	1
P1(a)	$P(+) = 0.254$	1.5
P1(b)	$P(S +) \approx 0.748$	1.5
P1(c)	Хибно: 25% «+» – не спам	1.5

Завдання	Відповідь	Бали
P1(d)	$E[\text{spam}] = 10, E[\text{TP}] \approx 9.5$	1.5
P2(a)	Валідний розподіл	1.5
P2(b)	$E[R] = -6.5\%$ — не вигідно	1.5
P2(c)	$SD(R) \approx 38.5\%$ — висока волатильність	1.5
P2(d)	$E[V] = \$467.5, SD(V) \approx \192.7	1.5
P3(a)	$P(X = 0) \approx 0.2785$	1.5
P3(b)	$P(X \geq 2) \approx 0.3417$	1.5
P3(c)	$E[X] = 1.2, \text{Var} = 1.056$	1.5
P3(d)	$P(X > 2) \approx 0.1087$	1.5
P4(a)	$P(X > 17\,000) \approx 0.059$	2
P4(b)	$x_{0.9} \approx 16\,096$	2
P4(c)	$P(8\,000 < X < 15\,200) \approx 0.7357$	2
P5(a)	$E[T] = 20, \text{Var}(T) = 400$	1.5
P5(b)	$P(T > 30) \approx 0.2231$	1.5
P5(c)	$P(10 < T < 40) \approx 0.4712$	1.5
P5(d)	$P(T > 30 \mid T > 20) \approx 0.6065$; memoryless	1.5
P6(a)	$P(T \geq 900) \leq 0.20$	2
P6(b)	Маркова дає рівно 15%; твердження валідне	2
P6(c)	Двочисловий розподіл $\{0, 900\}$ з масами $\{0.8, 0.2\}$	2
P7(a)	$\bar{X} \sim \mathcal{N}(5.8, 0.04)$; CLT	2
P7(b)	$P(\bar{X} < 5.5) \approx 0.0668$	2
P7(c)	$c \approx 6.129$ год	2
P8(a)	$p_X = (0.30, 0.50, 0.20)$; $p_Y = (0.30, 0.45, 0.25)$	1.5
P8(b)	$E[X] = 3.0, E[Y] = 1.9$	1.5
P8(c)	Не незалежні	1.5
P8(d)	$\text{Cov}(X, Y) = -0.80$	1.5

Завдання	Відповідь	Бали
P9(a)	$S_{XY} \approx 6.4167$	1.5
P9(b)	$r_{XY} \approx 0.467$	1.5
P9(c)	Помірний додатний лінійний зв'язок	1.5
P9(d)	Кореляція $\neq$ причинність; confounder	1.5
P10(a)	$E[X_i] = -10, \text{Var}(X_i) = 9\,900$	1.5
P10(b)	$S_{100} \sim \mathcal{N}(-1\,000, 995^2); \text{CLT}$	1.5
P10(c)	$P(S_{100} > 0) \approx 0.1575$	1.5
P10(d)	$\bar{X}_n \rightarrow -10$; «грати до перемоги» приречено	1.5